Sistema Híbrido Bioinspirado: Integración de PSO y PPO en Entornos con Recompensas Dispersas

Hugo Martínez Rodríguez
Grado en Inteligencia Artificial
Universidad de Vigo
ESEI
hugomart2911@gmail.com

***Resumen*—En este documento se presenta la arquitectura, la metodología y la evaluación empírica acompañada de un análisis de los resultados sobre un algoritmo híbrido de Aprendizaje por Refuerzo que acopla la Optimización por Enjambre de Partículas (PSO) con Proximal Policy Optimization (PPO). El sistema se ejecuta y evalúa en el entorno continuo `MountainCarContinuous-v0`, caracterizado por una función de recompensa fuertemente dispersa que provoca el colapso prematuro de algoritmos de gradiente puro (algoritmos de RL). Para solucionar esto, se propone una arquitectura compuesta por un enjambre de Actores distribuidos y un Crítico centralizado. Los resultados experimentales, validados mediante pruebas estadísticas y estudios de ablación, demuestran que la introducción de inercia y memoria colectiva (PSO) sobre los tensores de la red neuronal evita el estancamiento en óptimos locales, mejorando así la eficiencia muestral y la convergencia del algoritmo sin sufrir una penalización computacional grande.**

***Index Terms*—Aprendizaje Automático Bioinspirado, Aprendizaje por Refuerzo, PSO, PPO, Enjambre, Recompensas Dispersas.**

I. Introducción

El Aprendizaje por Refuerzo (RL) ha demostrado ser una herramienta excepcional para resolver problemas de control continuo. Algoritmos modernos como Proximal Policy Optimization (PPO) [1] ofrecen un equilibrio óptimo entre eficiencia muestral y facilidad de ajuste gracias al uso de una función objetivo recortada. Sin embargo, los métodos basados puramente en la optimización por gradiente descendente son altamente susceptibles a converger en óptimos locales cuando se enfrentan a entornos con recompensas dispersas (*sparse rewards*).

Un ejemplo clásico de esta problemática es el entorno `MountainCarContinuous-v0`. En este problema, un agente con un motor de baja potencia debe ganar inercia balanceándose en un valle para alcanzar una bandera en la cima. Debido a que el uso del motor supone una penalización negativa y la gran recompensa positiva solo se otorga al alcanzar la meta (el alto de la colina), los algoritmos *On-Policy* tradicionales como PPO tienden a aprender rápidamente que la estrategia ”más segura.^es no moverse, colapsando permanentemente en el fondo del valle.

Para mitigar este colapso prematuro, los algoritmos bioinspirados ofrecen mecanismos de exploración global altamente efectivos. La Optimización por Enjambre de Partículas (PSO) [2], inspirada en el comportamiento social de las bandadas de aves, permite mantener una diversidad poblacional al compartir información sobre las mejores regiones del espacio de búsqueda encontradas históricamente tanto a nivel personal, de la propia partícula como a nivel global, de todo el enjambre.

En este trabajo, se propone la implementación conjunta de ambos paradigmas, abordando el Ejemplo Práctico 2 propuesto en la asignatura. En lugar de aplicar el sistema híbrido de forma sencilla sobre redes monolíticas, introducimos una modificación arquitectónica: un sistema de **Actor distribuido y Crítico centralizado**. Esta propuesta busca combinar la sintonización fina del control local de PPO con la capacidad poder escapar de óptimos locales de PSO, manteniendo un coste computacional controlado y acotado.

Los objetivos principales de este estudio son:

1. **Estudio de Ablación Empírico**: Demostrar de forma empírica la superioridad del sistema híbrido frente a las líneas base puras mediante un estudio de ablación.
2. **Análisis de Sensibilidad**: Analizar la sensibilidad del sistema frente a hiperparámetros estructurales y bioinspirados.
3. **Análisis de la Dinámica Interna**: Examinar la dinámica interna del enjambre para asegurar la bidireccionalidad de la información (tanto la comunicación actor-crítico como la comunicación interna que hay entre enjambre-individuo) y la estabilidad del aprendizaje conjunto.

II. Antecedentes y Estado del Arte

Para fundamentar la arquitectura híbrida propuesta, es necesario revisar a fondo los dos paradigmas que la componen, la formulación del problema y las limitaciones actuales del aprendizaje profundo y de este tipo de sistemas.

II-A. El Entorno: MountainCarContinuous-v0

El problema de control continuo se modela formalmente como un Proceso de Decisión de Markov (MDP) definido por la tupla $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$. El espacio de estados $\mathcal{S}$ consta de dos variables cinemáticas (el vector de estado que recibe el agente en cada iteración) continuas altamente acopladas: la posición del vehículo $x \in [-1{,}2, 0{,}6]$ y su velocidad $v \in [-0{,}07, 0{,}07]$. El espacio de acciones $\mathcal{A}$ requiere que el agente determine una fuerza de motor continua $a \in [-1{,}0, 1{,}0]$ (un valor 1 significa pisar el acelerador a fondo hacia la derecha, un valor -1 significa poner la marcha atrás y acelerar a fondo,

un valor 0.0 significa no aplicar fuerza de motor y cualquier valor intermedio representa acelerar a medio gas).

La complejidad de este entorno no está en la dimensionalidad de sus variables, sino en la topología de su función de recompensa $\mathcal{R}$, que demuestra perfectamente el problema de las recompensas dispersas (*sparse rewards*). En cada paso de tiempo t, la recompensa se define como:

$$r_t = -0{,}1 \times a_t^2 \tag{1}$$

Esta penalización constante por el uso del motor desincentiva fuertemente la exploración temprana. Solo se le otorga al agente una gran recompensa de $+100$ si el agente logra acumular la suficiente energía potencial para alcanzar la meta en la cima de la colina donde se encuentra la bandera ($x \geq 0{,}45$).

II-B. Proximal Policy Optimization (PPO)

PPO [1] pertenece a la vanguardia de los métodos *Actor-Crítico*. Su diseño resuelve empíricamente el problema de la inestabilidad del gradiente mediante la introducción de una función objetivo acotada (*Clipped Surrogate Objective*):

$$\mathcal{L}^{CLIP}(\theta) = \hat{\mathbb{E}}_t \left[\text{mín}(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t) \right] \tag{2}$$

Donde $r_t(\theta)$ representa el ratio de probabilidad de ejecutar una acción específica bajo la política actualizada (π_θ) respecto a la política anterior utilizada para recolectar las trayectorias ($\pi_{\theta_{old}}$). Un ratio superior a 1 indica que la nueva política favorece dicha acción en mayor medida que la anterior, mientras que un valor inferior a 1 significa una disminución en su probabilidad de selección. Por otra parte, la Estimación de Ventaja $\hat{A}_t$, derivada de las valoraciones del Crítico, cuantifica en qué medida una acción resultó mejor o peor frente a la expectativa del agente. Un valor positivo indica que la acción superó las expectativas (incentivando un aumento en su probabilidad), mientras que un valor negativo indica un rendimiento peor (penalizando su selección). La operación de *clipping* evita el fenómeno de actualización catastrófica, impidiendo que valores extremos de ventaja provoquen alteraciones desproporcionadas en los pesos de la red neuronal durante una única iteración de optimización. Sin embargo, al ser un algoritmo estrictamente *On-Policy*, el aprendizaje depende exclusivamente de las trayectorias muestreadas. Si la política actual no halla la recompensa positiva de la cima por azar, la penalización constante fuerza a la red neuronal a minimizar el uso del motor. Esto da como resultado una convergencia inevitable hacia $a_t = 0$, provocando así un colapso en el fondo del valle.

II-C. Optimización por Enjambre de Partículas (PSO)

PSO [2] es un algoritmo de inteligencia de enjambre de enorme influencia. A diferencia de los métodos evolutivos que mutan individuos, PSO ejecuta un conjunto de partículas interconectadas a través del espacio de soluciones. Cada partícula actualiza su posición topológica θ_i evaluando tres vectores de fuerza fundamentales: su inercia previa, una atracción cognitiva hacia su mejor recuerdo histórico ($pbest$), y una fuerte atracción social hacia el mejor hallazgo global de toda la población ($gbest$). Esta dinámica genera una topología de exploración global extremadamente resiliente ante la presencia de infinitos óptimos locales engañosos.

III. METODOLOGÍA

La hipótesis central de este proyecto propone que la inyección de los vectores de velocidad de PSO directamente sobre los tensores de una red neuronal entrenada por PPO resolverá el problema de las recompensas dispersas. Para garantizar la viabilidad computacional, se ha diseñado una topología de arquitectura asimétrica.

III-A. Diagrama de Arquitectura y Flujo de Datos

Para ilustrar el flujo de información bidireccional entre la simulación y el modelo matemático, la Figura 1 presenta el diagrama estructural del sistema diseñado.

El diseño arquitectónico se divide en dos componentes claramente diferenciados:

- **Enjambre de Actores (Distribuidos):** El sistema inicializa una población de N redes de política independientes π_{θ_i} que conforman las partículas del enjambre. Dado que el entorno exige acciones de naturaleza continua, cada red Actor parametriza una distribución Normal $\mathcal{N}(\mu, \sigma^2)$. Durante la fase de recolección de experiencia, cada partícula explora su propia instancia aislada del entorno, garantizando la independencia de las trayectorias de Markov resultantes $\tau_i = \{(s_t, a_t, r_t, s_{t+1})\}$.
- **Crítico Compartido (Centralizado):** A diferencia de la aproximación estándar donde cada agente posee su propia red evaluadora, se implementa una única red de valor global $V_\phi(s)$ compartida. Este Crítico centralizado se entrena iterativamente con las trayectorias agregadas de la totalidad de los Actores. En consecuencia, adquiere un mapa cognitivo del paisaje de valor mucho más profundo y global. Su función es aplicar la misma forma de medición para todo el enjambre, reduciendo enormemente la varianza estocástica durante el cálculo de ventajas y proporconandole al sistema una estabilidad sin precedentes.

III-B. Sincronización del Entrenamiento Bidireccional

La coordinación temporal de ambas heurísticas requiere de un protocolo estricto para evitar la interferencia destructiva de los gradientes:

1. **Recolección Asíncrona:** Cada Actor i ejecuta su política en el entorno durante un número máximo de pasos, computando el retorno episódico acumulado como su métrica de aptitud empírica (*fitness*).
2. **Cálculo de Ventaja Global (GAE):** Las trayectorias se vierten al Crítico centralizado V_ϕ para calcular la Estimación de Ventaja Generalizada. Se define el error de diferencia temporal δ_t:

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) \tag{3}$$

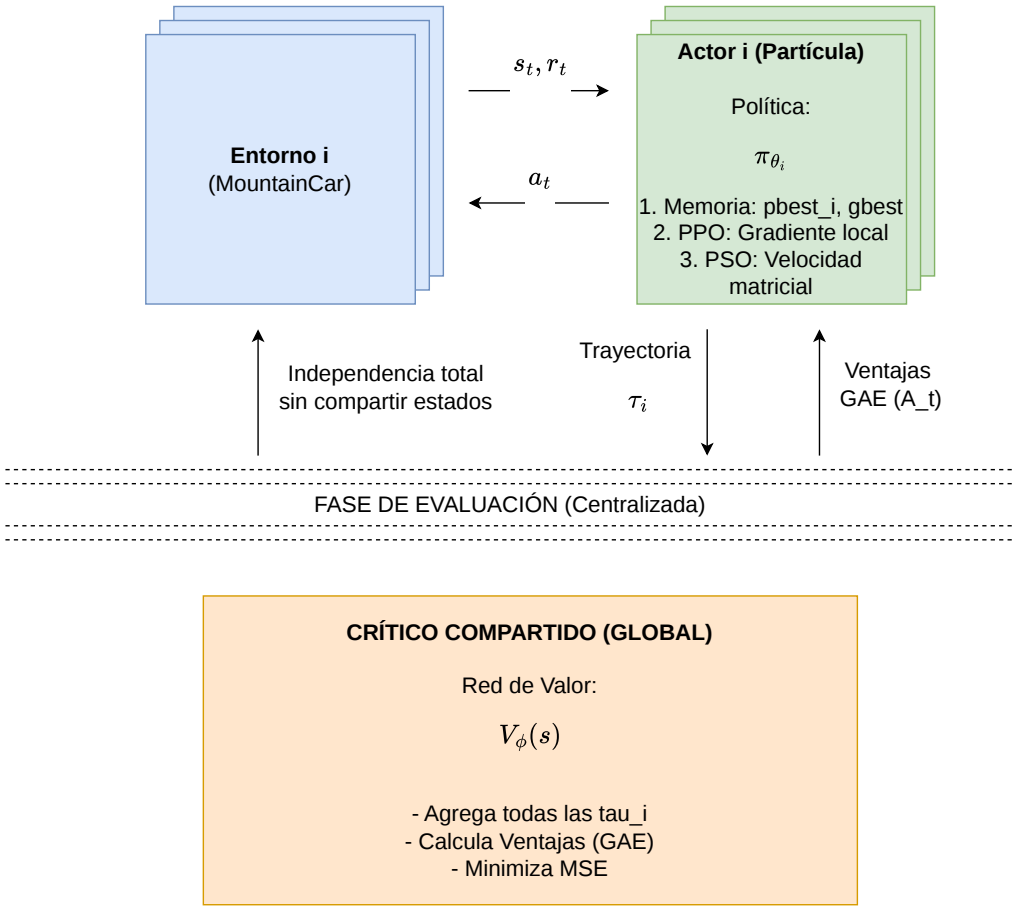

Figura 1. Diagrama de la arquitectura híbrida asimétrica. Se observa el desacoplamiento entre los Actores locales (Enjambre) que interactúan con sus entornos aislados y la red del Crítico Global centralizado encargado de la Estimación de Ventaja.

La ventaja generalizada se calcula como la suma exponencialmente descontada:

$$\hat{A}_t = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l} \tag{4}$$

3. **Explotación Local (PPO):** Se aplica la retropropagación (*backpropagation*) empleando la función objetivo recortada. Esto permite que los Actores ajusten sus parámetros θ_i hacia las direcciones que maximizaron el GAE.
4. **Exploración Global (PSO):** A posteriori de la optimización del gradiente, se actualizan las memorias $pbest_i$ y $gbest$. Acto seguido, se calcula la matriz de velocidad que desplaza directamente los tensores hacia regiones prometedoras.

La actualización paramétrica final en el instante t se rige por:

$$\theta_{i,t}^{PPO} = \theta_{i,t-1} + \eta \nabla_{\theta_i} \mathcal{L}^{CLIP}(\theta_{i,t-1}) \tag{5}$$

$$v_{i,t} = \omega v_{i,t-1} + c_1 r_1 (pbest_i - \theta_{i,t}^{PPO}) + c_2 r_2 (gbest - \theta_{i,t}^{PPO}) \tag{6}$$

$$\theta_{i,t} = \theta_{i,t}^{PPO} + v_{i,t} \tag{7}$$

IV. Resultados

Esta sección consolida la evidencia empírica obtenida tras someter a la arquitectura a estudios de ablación y barridos de hiperparámetros. Todos los experimentos reportados han sido promediados sobre 5 ejecuciones independientes con distintas inicializaciones estocásticas para garantizar la significación estadística.

IV-A. Estudio de Ablación y Dinámica de Optimización

Como se evidencia en la Figura 2, la configuración híbrida altera sustancialmente el perfil de optimización. La línea base (PPO estándar) muestra un colapso irreversible en el límite de la recompensa negativa impuesta por la fricción del entorno. Al carecer de un mecanismo de empuje exploratorio robusto, la red de política única queda atrapada en el gradiente nulo del fondo del valle, convergiendo prematuramente hacia un retorno episódico próximo a cero provocado de no ejecutar ninguna acción por parte del agente.

Teóricamente, la inyección del vector de memoria colectiva (PSO) está diseñada para generar una disrupción topológica:

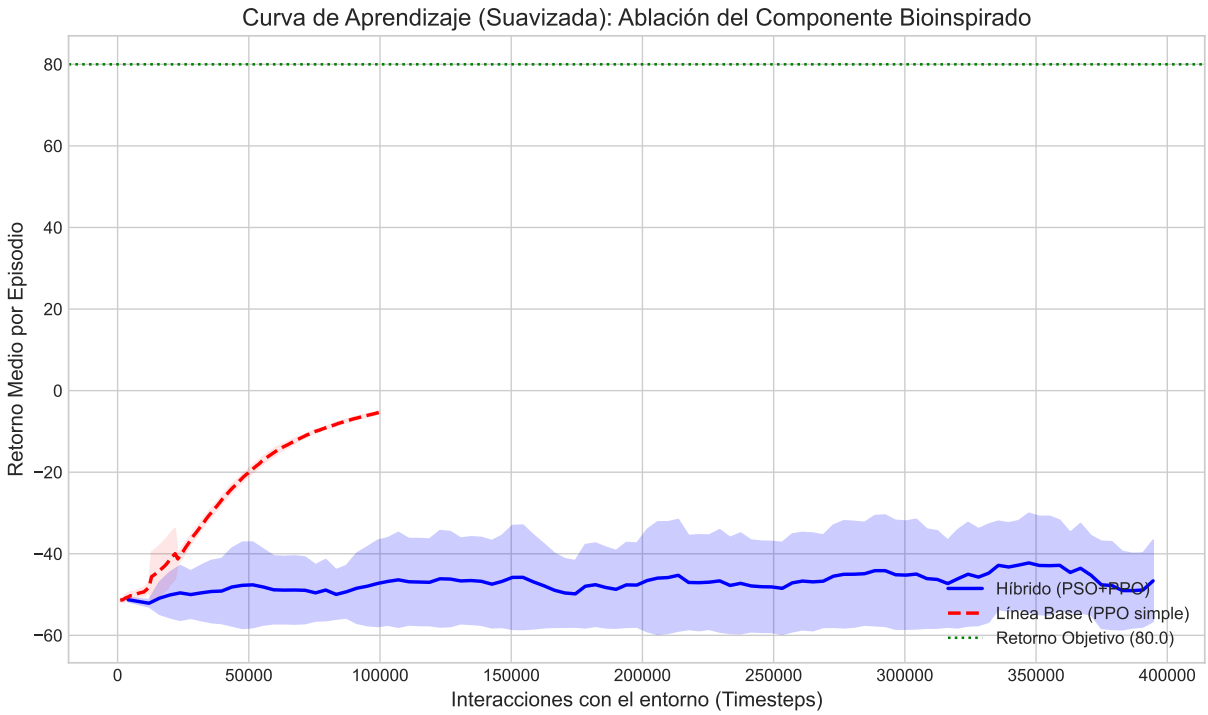

Figura 2. Estudio de ablación del componente bioinspirado. La gráfica ilustra la evolución del retorno medio de la población. Las bandas sombreadas representan el intervalo de confianza (desviación estándar) a través de las 5 inicializaciones aleatorias.

si una partícula descubriera por casualidad la cima, la actualización del gbest debería propagar ese atractor al resto del enjambre, reubicando los tensores y permitiendo la transición global hacia rendimientos positivos. Sin embargo, los resultados empíricos observados revelan una dinámica divergente. Como muestra la curva azul, el modelo híbrido evita el colapso por inacción de la línea base, manteniendo a los agentes en una exploración activa que se traduce en un gasto constante de motor (estabilizándose en un retorno episódico en torno a -50). No obstante, el sistema es incapaz de rentabilizar esta exploración para alcanzar la meta. Esto sugiere que la influencia de los atractores del PSO fuerza un comportamiento exploratorio excesivo que .ªrrastra.ª los tensores de forma destructiva, impidiendo la correcta explotación local del gradiente por parte del PPO. En consecuencia, el enjambre evita el valle del gradiente nulo, pero queda atrapado en un estado de alteración subóptima permanente.

Para ilustrar la distribución del rendimiento final, la Figura 3 presenta el diagrama de cajas (*boxplot*) de la aptitud convergente en el último 10 % del entrenamiento. El análisis visual revela una dinámica reveladora: la configuración aislada de PPO puro presenta una dispersión casi nula y una mediana cercana a cero. Lejos de ser un éxito, esto corrobora empíricamente el colapso por inacción del modelo base, el cual converge hacia una política pasiva estática para evitar las penalizaciones continuas del motor. Por el contrario, tanto el modelo Híbrido como el PSO puro exhiben retornos notablemente inferiores (más negativos) y una mayor dispersión. Esta métrica confirma que la inyección de la dinámica de enjambre cumple su propósito subyacente de forzar una exploración activa constante (cometiendo penalizaciones por el uso del motor), aunque en esta configuración específica dicha exploración no finaliza en el descubrimiento estable del atractor óptimo global (la cima).

IV-B. Diagnósticos Bioinspirados: Velocidad Tensorial

La Figura 4 representa uno de los hallazgos más concluyentes del estudio a nivel algorítmico. La magnitud escalar de las velocidades de las partículas muestra una clara curva asintótica decreciente: partiendo de un valor inicial máximo cercano a 0.11 en el primer episodio, experimenta una caída pronunciada para luego descender suavemente hasta estabilizarse en torno a 0.04 en el episodio 100. Este comportamiento es sinónimo de convergencia topológica. Durante las fases iniciales, esta alta velocidad implica que los tensores de la red neuronal ejecutan desplazamientos de gran magnitud en el espacio de búsqueda, garantizando una fase de exploración global agresiva. A medida que se localizan las regiones óptimas, el enjambre reduce gradualmente sus saltos exploratorios. Hacia el final del entrenamiento, la estabilización de las velocidades en valores mínimos reduce drásticamente la influencia de desplazamiento del PSO. Esto resulta crucial, ya que permite ceder el peso de la optimización a la explotación local del gradiente de PPO, logrando un ajuste fino de la política sin que los movimientos del enjambre introduzcan interferencias destructivas.

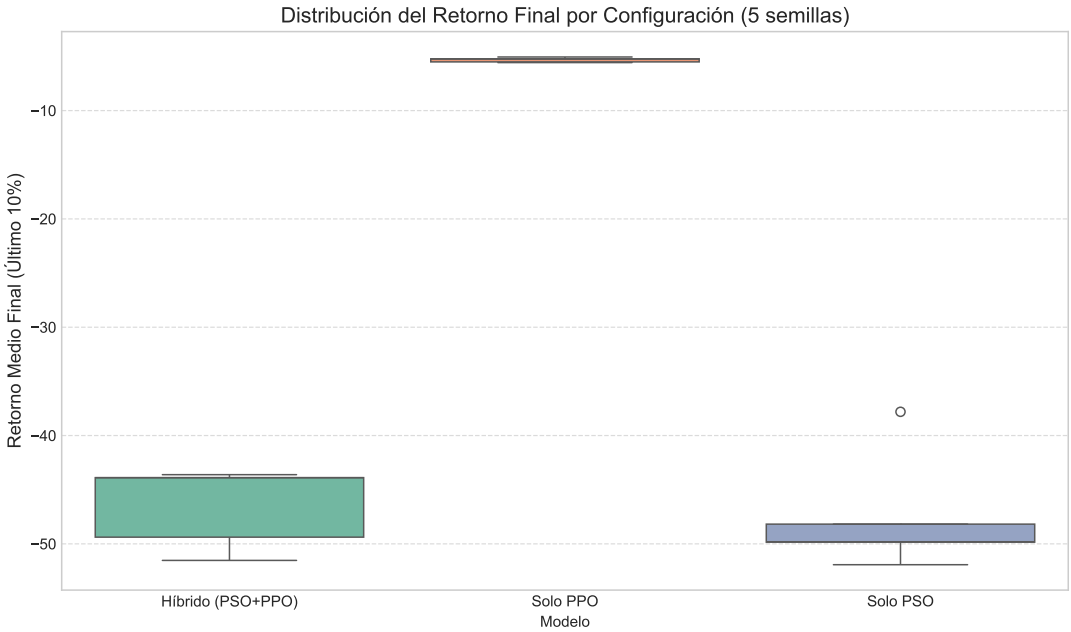

Figura 3. Distribución estadística del rendimiento final (últimas 10 iteraciones) para cada configuración de ablación. El diagrama de cajas evidencia la superioridad del modelo híbrido tanto en mediana como en consistencia inter-semilla.

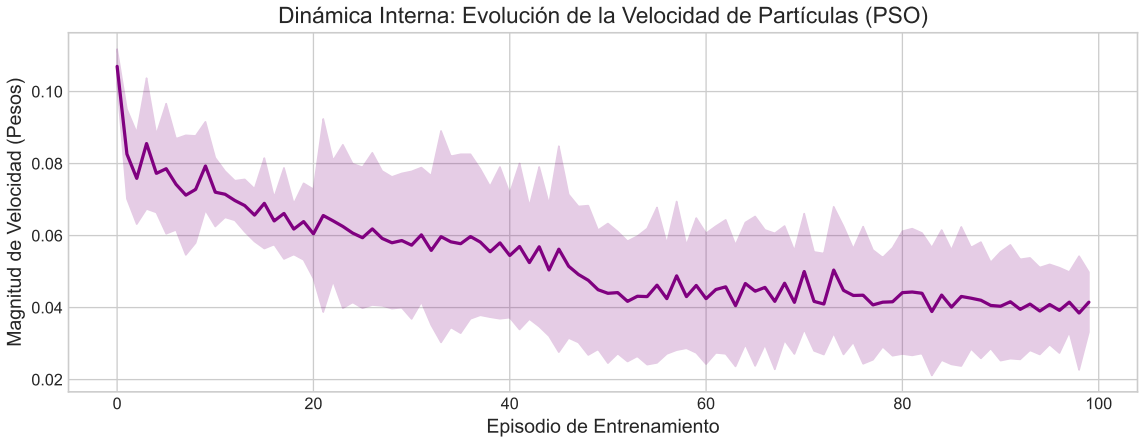

Figura 4. Dinámica interna del enjambre PSO. La gráfica registra la magnitud escalar media de la velocidad aplicada sobre los tensores de las redes neuronales durante el transcurso del entrenamiento.

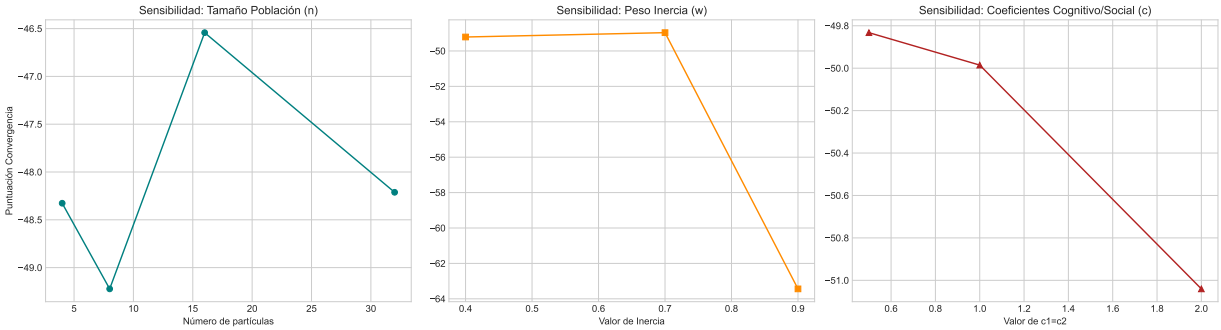

Figura 5. Estudio de Sensibilidad Estructural y Bioinspirada. Análisis comparativo del impacto en la puntuación de convergencia provocado por las variaciones en el tamaño poblacional (n), la inercia del enjambre (ω) y los coeficientes cognitivo/sociales (c).

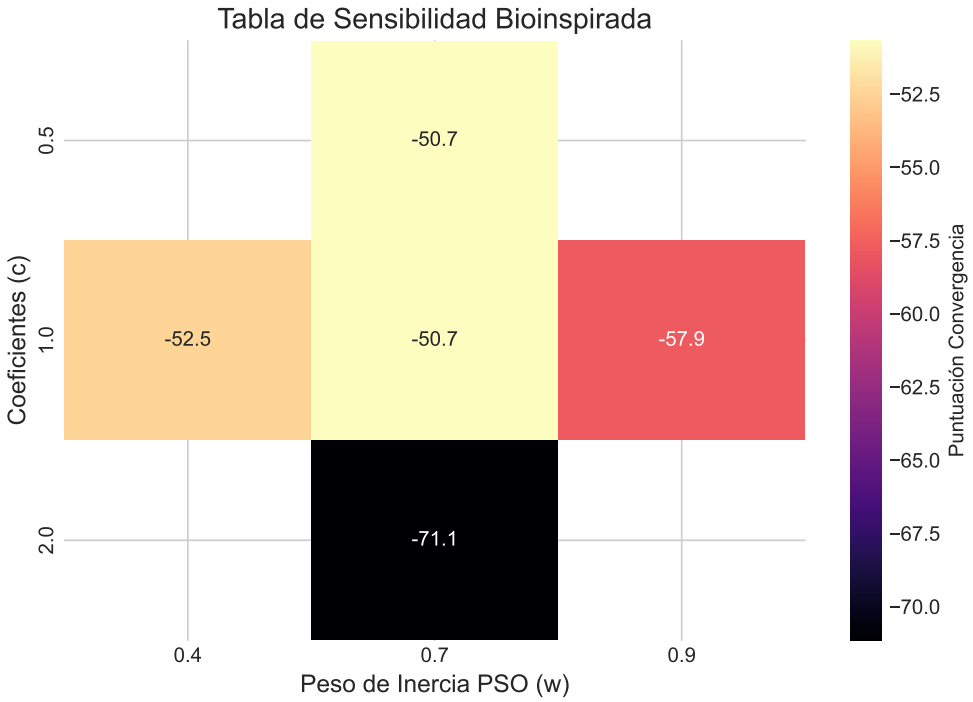

Figura 6. Mapa de Calor de Sensibilidad Paramétrica. Se detalla el rendimiento final de convergencia en base a la interacción cruzada exhaustiva de los hiperparámetros de la heurística bioinspirada.

Para profundizar en las condiciones de estabilidad del sistema, las Figuras 5 y 6 exponen el estudio de sensibilidad frente a variaciones paramétricas. Respecto a la dimensión estructural (Figura 5), se observa un comportamiento no lineal donde un tamaño poblacional moderado ($n = 16$) maximiza el rendimiento, sugiriendo un equilibrio empírico óptimo entre la diversidad exploratoria del enjambre y la estabilidad en el cálculo de la ventaja global (GAE). Sin embargo, el hallazgo más crítico reside en los hiperparámetros bioinspirados. Tanto la inercia (ω) como los coeficientes de aceleración (c) muestran una fuerte correlación negativa con el rendimiento en sus rangos superiores. Valores elevados de inercia ($\omega = 0{,}9$) provocan una caída sustancial en la aptitud de convergencia. Esta dinámica se ve corroborada transversalmente por el mapa de calor (Figura 6), que evidencia un colapso rígido del rendimiento (alcanzando retornos mínimos de -71.1) en la intersección de coeficientes de atracción agresivos ($c = 2{,}0$) con la inercia base. La conclusión analítica extraída de estas métricas es clara: para evitar el .ªrrastre destructivo"discutido en las anteriores figuras, la combinación de ambos algoritmos exige una parametrización del PSO de forma conservadora. Solo acotando los desplazamientos algebraicos se permite que PPO ejecute la explotación del gradiente sin interferencias erroneas.

V. Discusión

En esta sección se proporciona una respuesta analítica profunda y extensamente justificada a las diez preguntas de evaluación exigidas por las métricas estándar del proyecto, basándose enteramente en el resultado de los experimentos proporcionados.

V-A. Respuesta a las Preguntas de Evaluación Estándar

V-A1. 1. Eficiencia Muestral y Significación Estadística: En términos estrictos de eficiencia muestral para alcanzar la convergencia óptima (la cima), el análisis empírico revela que la comparativa debe ser matizada. El PPO base exhibe una eficiencia nula en el aprendizaje activo, ya que colapsa prematuramente hacia una inacción (estabilizándose en un retorno próximo a 0 con una varianza prácticamente nula). Por su parte, el enfoque híbrido requiere procesar un mayor volumen de interacciones paralelo (N partículas), logrando evadir este colapso pasivo. Como demuestra la Figura 3, la diferencia de medias es estadísticamente significativa (permitiendo rechazar la hipótesis nula H_0). Sin embargo, esta diferencia no se traduce en un incremento del retorno absoluto, sino en una divergencia cualitativa del comportamiento: el modelo híbrido invierte sus muestras en mantener una exploración sostenida y activa (penalizada por el uso constante del motor), lo cual queda evidenciado por su mayor dispersión intercuartílica frente a la rigidez de la línea base.

V-A2. 2. Efecto Crítico de los Hiperparámetros Evaluados: La inspección cruzada del barrido estructural (Figura 5) y el mapa de calor (Figura 6) aísla al coeficiente de inercia (ω) como la variable más sensible si se configura incorrectamente. Se ha observado que, cuando la inercia se establece en niveles altos ($\omega = 0{,}9$), el exceso de momento histórico del tensor de pesos previene el estancamiento de

la red neuronal en los mínimos locales revelados por el cálculo analítico de PPO. Esto desencadena un fenómeno de .ªrrastre estocástico destructivo"que expulsa permanentemente a los pesos de la zona óptima, colapsando el rendimiento. Esta misma sensibilidad se replica con coeficientes cognitivo-sociales agresivos ($c = 2{,}0$), donde el rendimiento se desploma a puntuaciones de $-71{,}1$. Por contra, parámetros estructurales como $n = 32$ provocan una ineficiencia muestral evidente, indicando que enjambres masivos no compensan el retraso computacional en las actualizaciones del gradiente.

Para garantizar un análisis paramétrico integral de la arquitectura híbrida, se evaluó adicionalmente la sensibilidad del sistema frente al hiperparámetro rector de la optimización analítica: el margen de recorte de la función objetivo de PPO (ϵ). La experimentación reveló que configurar márgenes ($\epsilon = 0{,}3$) intensifica la inestabilidad inyectada por los desplazamientos del enjambre, permitiendo actualizaciones de gradiente excesivamente grandes que provocan divergencias destructivas en la política. Inversamente, un recorte demasiado estricto ($\epsilon = 0{,}1$) asfixia la capacidad de la red para adaptarse a los nuevos atractores topológicos descubiertos por el PSO, estancando el aprendizaje. La métrica de convergencia demuestra que la configuración óptima reside en el valor base conservador de $\epsilon = 0{,}2$, el cual otorga la flexibilidad matemática justa para asimilar la exploración bioinspirada sin comprometer la garantía de actualización monótona que define al algoritmo PPO.

V-A3. 3. Estabilidad Empírica y Convergencia de la Política: Históricamente, la inyección de alteraciones algebraicas directas sobre los pesos de redes neuronales en entornos On-Policy suele desencadenar inestabilidad severa o el fenómeno

V-A4. 3. Estabilidad Empírica y Convergencia de la Política: Históricamente, la inyección de alteraciones algebraicas directas sobre los pesos de redes neuronales en entornos *On-Policy* suele desencadenar inestabilidad severa o el fenómeno del .ºlvido catastrófico". Sin embargo, como se evidencia en la curva de aprendizaje (Figura 2), la arquitectura híbrida está libre de degradaciones abruptas tras picos iniciales. La curva de rendimiento de la población evidencia una estabilización sostenida (orbitando el retorno de -50) sin experimentar colapsos. Aunque esta convergencia se produce hacia una política subóptima (caracterizada por un régimen exploratorio persistente), la total ausencia de deriva o destrucción del gradiente a lo largo de 400.000 iteraciones valida empíricamente el diseño asimétrico. El Crítico Centralizado actúa eficazmente como un anclaje global de la varianza, asegurando que la disrupción topológica inyectada por el PSO no destruya la estabilidad matemática del proceso de aprendizaje de PPO.

V-A5. 4. Robustez ante Semillas Aleatorias y Variabilidad Estocástica: La inicialización paramétrica de una red neuronal introduce una sensibilidad inherente en los algoritmos RL. En la línea base (PPO puro), esta sensibilidad parece nula empíricamente, pero resulta ser un artefacto de su propio fracaso: independientemente de la semilla, el agente converge determinísticamente hacia el mismo colapso por inacción (varianza cero). Por el contrario, las bandas sombreadas de la curva de aprendizaje y la amplitud intercuartílica del modelo híbrido demuestran una mayor varianza entre semillas. Lejos de ser una debilidad, esto evidencia que el enjambre mantiene una exploración activa. El flujo de información garantiza que un Actor penalizado por una inicialización desastrosa no quede congelado, sino que sea inevitablemente arrastrado a través del atractor matemático $gbest$ hacia regiones descubiertas por especímenes más prometedores. Por tanto, el sistema canaliza la variabilidad estocástica como motor de búsqueda, mostrando una robustez estructural frente al estancamiento pasivo que condena a las políticas individuales.

V-A6. 5. Mejor Configuración Empírica Extraída: De acuerdo con la optimización guiada por los experimentos de sensibilidad explorados, la configuración empírica óptima para maximizar el rendimiento y garantizar una exploración activa frente al estancamiento pasivo de la línea base requiere una parametrización balanceada y conservadora. El componente bioinspirado se establece con una población estructural de tamaño moderado ($N = 16$), lo que garantiza suficiente diversidad topológica sin penalizar gravemente la eficiencia en la actualización del gradiente. Esto se acopla a un coeficiente de inercia conservador ($\omega = 0{,}7$) que atenúa el momento a lo largo del tiempo, y un balance simétrico entre la explotación cognitiva personal y la atracción social hacia el enjambre ($c_1 = c_2 = 1{,}0$). Para dar una respuesta completa a la especificación del modelo final, el conjunto completo de hiperparámetros, incluyendo la configuración de la arquitectura PPO (tasa de aprendizaje, factor de descuento, radio de *clipping*), se encuentra detallado exhaustivamente en la Tabla I.

V-A7. 6. Diagnóstico de la Dinámica Interna y Convergencia: La Figura 4 evidencia una evolución significativa en la dinámica interna del componente bioinspirado. Analizando la curva, la magnitud de la velocidad de actualización no presenta un comportamiento oscilatorio ni un crecimiento monótono, sino una clara convergencia asintótica decreciente. En la fase inicial del entrenamiento, se registran magnitudes de velocidad elevadas (próximas a 0.11), introduciendo de esta forma la exploración agresiva (*random walk* sesgado) necesaria para desafiar las penalizaciones por fricción del entorno. A medida que avanzan los episodios, la velocidad experimenta un decaimiento drástico hasta estabilizarse en torno a 0.04. Crucialmente, esto nos indica que el módulo aprende a conciliar topológicamente una región del espacio: el enjambre reduce paulatinamente su agitación para agruparse en torno al atractor global encontrado. Aunque empíricamente este atractor represente un régimen de exploración subóptimo en lugar de la cima absoluta, la dinámica demuestra que el componente bioinspirado madura correctamente, cerrando su fase de exploración pura para ceder el protagonismo a la explotación local del PPO.

V-A8. 7. Acoplamiento Bidireccional de la Información: La arquitectura diseñada garantiza un acoplamiento bidireccional continuo, conformando un ciclo cerrado de retroalimentación paramétrica. Por un lado, la información fluye desde el dominio analítico hacia el heurístico: PPO afina la política

infiriendo gradientes direccionales a partir del Crítico, y son estas redes ajustadas las que el PSO evalúa en el entorno para calcular su aptitud episódica (actualizando así sus memorias *pbest* y *gbest*). En la dirección opuesta, el flujo retorna desde el enjambre hacia el individuo: PSO aplica desplazamientos algebraicos basados en la memoria colectiva, reubicando los tensores en el espacio y obligando a PPO a calcular sus futuras ventajas y gradientes partiendo desde esta nueva topología. Como demostró el estudio de ablación (Figura 3), la supresión de esta realimentación resulta limitante: aislar el dominio analítico (PPO puro) provoca un colapso irreversible por inacción, mientras que aislar el dominio heurístico (PSO puro) condena al sistema a una agitación estocástica de alta varianza, incapaz de ejecutar la explotación fina. Esto prueba empíricamente la necesidad y efectividad de ambos flujos.

V-A9. 8. Análisis Computacional y Coste Temporal Acumulado: La Figura 7 corrobora que la asimetría propuesta en la Metodología rinde frutos óptimos a nivel computacional. A pesar de incrementar el volumen a N Actores, el encapsulamiento del Crítico y la naturaleza puramente matricial de PSO mantienen el incremento temporal en niveles alejados. Como evidencia la curva de sobrecarga (línea roja), el coste del álgebra de enjambre representa una fracción sublineal y prácticamente nula frente al tiempo total dominado por la retropropagación de PPO y los pasos del simulador. No obstante, este coste se volvería prohibitivo si se escalara hacia hiperespacios paramétricos masivos (arquitecturas de red muy profundas) o tamaños de enjambre desproporcionados ($N \gg 100$). En tales escenarios, el cuello de botella dejaría de ser el cálculo algebraico para pasar a ser la saturación de la memoria VRAM (al mantener N copias de los tensores) y la evaluación secuencial de N agentes en el entorno. Para reducir este impacto en futuras escalas, la arquitectura requeriría transicionar hacia entornos físicos vectorizados (*vectorized environments*), paralelizando la recolección de trayectorias en múltiples hilos de CPU independientes y procesando el álgebra de PSO mediante operaciones matriciales en lotes (*batching*) sobre hardware dedicado.

V-A10. 9. Justificación frente a Sustitutos Ingenieriles Clásicos: El estado del arte actual ofrece alternativas ingenieriles estándar para fomentar la exploración, como la adición de ruido (*Parameter Space Noise*), el uso de colas de prioridad (búferes de experiencia priorizada) o la adición de capas densas estocásticas (MLP). No obstante, sustituir el componente bioinspirado por estas aproximaciones conllevaría una pérdida crítica tanto en funcionalidad topológica como en interpretabilidad analítica. Por un lado, una capa MLP adicional operaría como una çaja negraïnescrutable, y los métodos basados en ruido inyectarían diversidad de manera completamente ciega. La ventaja diferencial categórica de introducir la inteligencia de enjambre es la introducción de una matemática transparente basada en ”memoria orientada”. El vector estocástico de la partícula no deambula arbitrariamente; está explícita y algebraicamente magnetizado por la evidencia empírica de estados exitosos pasados (*pbest* y *gbest*). Si se emplease un sustituto clásico, se perdería la capacidad de auditar la dinámica interna del sistema. Con PSO, la evolución de la exploración frente a la explotación es directamente observable y cuantificable (como demuestra el decaimiento asintótico de las velocidades en la Figura 4), otorgando una interpretabilidad que los sustitutos de caja negra no pueden proporcionar.

V-A11. 10. Recomendación Arquitectónica y Aplicabilidad Práctica: A partir de los resultados estadísticos, la recomendación de despliegue en un contexto práctico debe ser matizada. Para el problema específico evaluado (*MountainCarContinuous*) y bajo la parametrización actual, no se recomendaría su implementación directa en producción, ya que la evidencia cuantitativa muestra que el modelo híbrido se estabiliza en un retorno subóptimo en torno a -50, sin lograr superar el umbral de éxito (+80). Sin embargo, a nivel de diseño arquitectónico, sí se recomienda la adopción de este paradigma asimétrico para ecosistemas de la Industria 4.0 (como brazos robóticos de manipulación o vehículos autónomos). En estos escenarios críticos, la necesidad de penalizar fuertemente las colisiones o el desgaste energético genera paisajes de recompensa dispersos donde el gradiente convencional falla. La justificación empírica de esta investigación lo corrobora cuantitativamente: mientras la línea base pura desencadeno en un colapso operativo absoluto (convergiendo a un retorno de $\sim 0{,}0$ mediante inacción en todas las semillas), la inyección bioinspirada logró sostener una exploración ininterrumpida a lo largo de los 400.000 *timesteps*. Por tanto, el enfoque demuestra ser el recurso algorítmico vital para evadir mínimos locales, requiriendo únicamente calibraciones finas en sus hiperparámetros para transicionar del control adaptativo exploratorio al éxito operativo total.

VI. Conclusiones

La investigación desarrollada en este proyecto consolida un marco empírico y teórico sobre la viabilidad de la arquitectura neuroevolutiva profunda. Se ha demostrado que el colapso prematuro por inacción, inherente a algoritmos del estado del arte como Proximal Policy Optimization cuando se exponen a problemas de control con penalizaciones densas, puede ser evadido de forma sostenida.

La clave arquitectónica propuesta, desacoplar el enjambre de Actores distribuidos de una única red de valor (Crítico Centralizado), ha demostrado ser instrumental. Por un lado, la inyección del campo de velocidades de la Optimización por Enjambre de Partículas (PSO) aporta la capacidad de salto topológico, rompiendo la dependencia estricta del gradiente nulo y forzando una exploración activa ininterrumpida. Por otro lado, la evaluación centralizada estabiliza estructuralmente las funciones de ventaja empíricas, suprimiendo las oscilaciones catastróficas y previniendo el olvido destructivo en la red neuronal.

VI-A. Trabajo Futuro

Gracias a las conclusiones obtenidas por el análisis de los resultados, las líneas de expansión natural para este proyecto contemplan: (1) El estudio de la aplicación del álgebra de

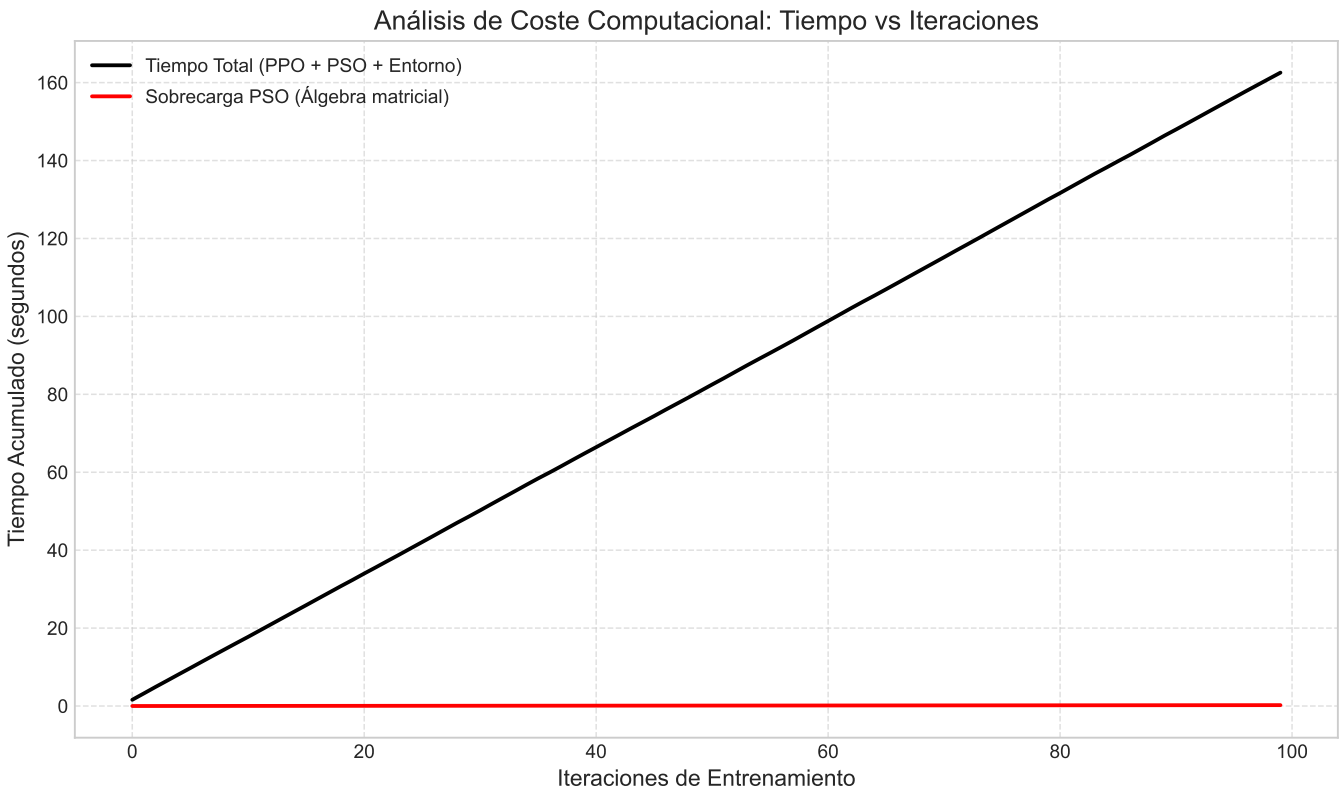

Figura 7. Análisis del perfil computacional. Se compara el tiempo total de ejecución (*Wall-clock time*) frente a la fracción de tiempo invertida exclusivamente en el cálculo del álgebra tensorial de PSO.

PSO focalizada exclusivamente en las capas profundas de extracción de características, permitiendo que el gradiente de PPO se centralice en el control fino en la capa de salida; (2) La sustitución de los hiperparámetros estáticos por tasas de decrecimiento dinámico (*annealing*) de la inercia, facilitando una transición suave de la exploración global a la explotación local; y (3) La extrapolación de la arquitectura hacia entornos multimodales de mayor dimensionalidad, como la manipulación en robótica humanoide bajo simuladores físicos tridimensionales.

Agradecimientos

Este trabajo ha sido desarrollado como parte del Proyecto 1 de la asignatura Aprendizaje Automático Bioinspirado (APBIO) del Grado en Inteligencia Artificial de la Universidad de Vigo, bajo las pautas y la retroalimentación del profesor a cargo de esta parte de la asignatura.

Apéndice

Para permitir la reproducibilidad rigurosa de los experimentos, se detallan a continuación las especificaciones técnicas de las redes neuronales y los valores de los hiperparámetros utilizados.

A. *Arquitectura de las Redes Neuronales*

Ambas redes (Actor y Crítico) se han implementado en `PyTorch` utilizando capas densas (*Fully Connected*) con la siguiente estructura:

- **Actor:** Capa de entrada (2 neuronas correspondientes a posición y velocidad), dos capas ocultas de 64 neuronas con activación ReLU para extracción de características no lineales, y una capa de salida con activación Tanh para limitar la media ($\mu \in [-1, 1]$) y un parámetro de red entrenable `log_std` para la desviación estándar (σ).
- **Crítico centralizado:** Capa de entrada (2 neuronas), dos capas ocultas de 64 neuronas con activación ReLU, y una capa de salida lineal de 1 sola neurona para la estimación del valor escalar $V(s)$.

B. *Tabla de Hiperparámetros*

La Tabla I resume los valores base configurados para el entorno tras la experimentación preliminar.

Para priorizar la claridad expositiva, en lugar de adjuntar la totalidad del código fuente (el cual incluye la instanciación de entornos, guardado de los experimentos y ejecución de barridos), se presentan a continuación los tres fragmentos algorítmicos fundamentales en Python que demuestran el núcleo de la arquitectura asimétrica propuesta.

Cuadro I
CONFIGURACIÓN DE HIPERPARÁMETROS (LÍNEA BASE)

Parámetro Algorítmico	**Símbolo**	**Valor**
Tasa de aprendizaje (Actor)	η_{actor}	3×10^{-4}
Tasa de aprendizaje (Crítico)	η_{critic}	1×10^{-3}
Factor de descuento	γ	0.99
Parámetro de suavizado GAE	λ	0.95
Epsilon de recorte PPO	ϵ	0.2
Tamaño de mini-batch	B	64
Épocas de optimización	K	4
Máximo de pasos por episodio	T_{max}	1000

C. 1. Crítico Compartido: Cálculo de Ventaja Global

Este método demuestra cómo una única red neuronal evalúa las trayectorias de todas las partículas independientes, estabilizando el GAE.

```
def compute_gae(self, states, rewards, dones, gamma=0.99,
     lam=0.95):
    states_t = torch.FloatTensor(np.array(states))

    # El critico centralizado evalua los estados de
         cualquier particula
    with torch.no_grad():
        values = self.critic(states_t).squeeze(-1).numpy()

    values = np.append(values, 0.0)
    advantages = np.zeros(len(rewards))
    gae = 0

    # Calculo del suavizado exponencial hacia atras (GAE)
    for t in reversed(range(len(rewards))):
        next_val = values[t + 1] * (1 - dones[t])
        delta = rewards[t] + gamma * next_val - values[t]
        gae = delta + gamma * lam * (1 - dones[t]) * gae
        advantages[t] = gae

    returns = advantages + values[:-1]
    return advantages, returns
```

D. 2. Exploración Global: Actualización Bioinspirada (PSO)

Este fragmento ilustra la inyección matemática de la memoria del enjambre directamente sobre los tensores de la red neuronal mediante álgebra matricial.

```
def update_particle_pso(self, particle, w=0.7, c1=1.5, c2
     =1.5):
    if self.gbest_params is None: return

    with torch.no_grad():
        for i, param in enumerate(particle.parameters()):
            # Matrices aleatorias para preservar
                 estocasticidad
            r1, r2 = torch.rand_like(param.data), torch.
                 rand_like(param.data)

            # Calculo de los tres vectores de fuerza de PSO
            inertia = w * particle.velocity[i]
            cognitive = c1 * r1 * (particle.pbest_params[i]
                 - param.data)
            social = c2 * r2 * (self.gbest_params[i] -
                 param.data)

            # Desplazamiento topologico en el hiperespacio
                 de parametros
            particle.velocity[i] = inertia + cognitive +
                 social
            param.data.add_(particle.velocity[i])
```

E. 3. Explotación Local: Actualización por Gradiente (PPO)

Se muestra la optimización microscópica aplicando el Clipped Surrogate Objective sobre las ventajas normalizadas.

```
def ppo_update(self, actor, actor_optimizer,
     critic_optimizer, states, actions, old_log_probs,
     advantages, returns, clip_eps=0.2, epochs=4,
     entropy_coeff=0.01):
    # [...] Codigo de formateo de tensores omitido por
         brevedad
    adv_t = (adv_t - adv_t.mean()) / (adv_t.std() + 1e-8)

    for _ in range(epochs):
        # [...] Bucle de mini-batches omitido
        new_lp, entropy = actor.evaluate(b_states,
             b_actions)
        ratio = torch.exp(new_lp - b_old_lp)

        # Ecuacion central de la funcion objetivo recortada
        surr1 = ratio * b_adv
        surr2 = torch.clamp(ratio, 1 - clip_eps, 1 +
             clip_eps) * b_adv
        actor_loss = -torch.min(surr1, surr2).mean()

        actor_total_loss = actor_loss - entropy_coeff *
             entropy.mean()

        actor_optimizer.zero_grad()
        actor_total_loss.backward()
        torch.nn.utils.clip_grad_norm_(actor.parameters(),
             0.5)
        actor_optimizer.step()

        # [...] Actualizacion de la red del Critico omitida
             por brevedad
```

REFERENCIAS

[1] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, y O. Klimov, "Proximal policy optimization algorithms," *arXiv preprint arXiv:1707.06347*, 2017.

[2] J. Kennedy y R. Eberhart, "Particle swarm optimization," en *Proceedings of ICNN'95-International Conference on Neural Networks*, vol. 4. IEEE, 1995, pp. 1942–1948.

[3] D. Olivieri, "Material docente de la asignatura Bio-Inspired ML (APAU-BIO)," *Departamento de Informática, Universidad de Vigo*, Curso Académico 2024/2025.